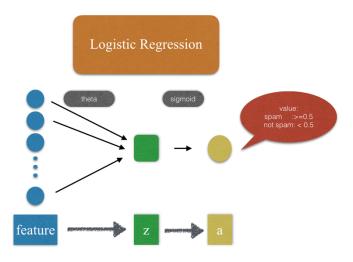
# [Machine Learning HW2] Logistic Regression R04921006 謝仲凱

這次的作業是來分辨信件是否為垃圾郵件 , Data是由助教提供的。

[Train]./train.sh spam\_train.csv model [Test]./test.sh model spam\_test.csv prediction.csv

## 1. (1%) Logistic regression function.



Cost function: Cross Entropy 硬生生的比Square Error 還厲害 比較不會卡在saddle points

Parameter update formula:

$$w_i \leftarrow w_i - \eta \sum_n - \left(\hat{y}^n - f_{w,b}(x^n)\right) x_i^n$$

#### Data

Training Data 分成:

Training Set = (9/10)筆 Training Data; Validation Set = (1/10)筆 Training Data Validation 非常的重要,因為它才是能正比於 Testing Data 正確率的標準,因此判斷 function 的好壞我會以 validation 為準則。

## Initial parameters

我認為參數值越接近0越好,因為這樣受到Noise 的影響會越少因此我的初始參數的 mean 為0。 Theta = 隨機的高斯函數值 (mu = 0, sigma=0.001)

# Learning Rate

大概試了一下, 大約在 (4.5 \* 10^-3) performance 最好

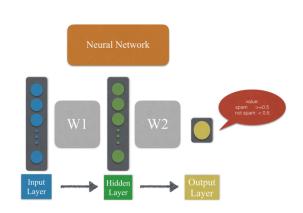
## • [Gradient Descent] mini batch vs full

看完全部更新一次: Validation performance 都只有在 90% 左右 mini batch : Validation performance 可以到達92% 左右 之所以有這樣的結果,我認為是因為如果有使用mini batch 每看完 batch\_size = (3,5,8,10 一起試) 筆資料就更新一次,可以使parameters 更符合資料的特性,使performance 得以提升。

(1%) Describe your another method, and which one is best.

#### **Neural Network**

(Hidden Layer 3~15個neuron 一起試)



of report percents, y, x, wisterion, x, values on, x, valu

Cost function: Cross Entropy

Parameter update formula: Backward Propagation (參考老師去年的講義)

- Data, Initial parameters, Learning Rate 設定方式與上述差不多
- Training Method (判斷function 夠不夠好):

與自己上次做法不同的地方是這次有使用accuracy threshold if(train\_acc >= train\_acc\_th and validation\_acc>=validation\_acc\_th ) 才會判定為是不錯的function,如果不夠好就重設initial parameter:因為我認為有好的開始是成功的一半,有好的initial parameter 分佈會讓accuracy 提高。

● [Public Score] Neural Network(0.94667) VS Logistic Regression(0.9233) 在這次的功課中,我的Logistic Regression 只能勉強比baseline多對一題,我認為是因為 Logistic Regression 只能做線性的分類,然而這次的spam 並非單純的線性model就可以分得很好,會有些data剛好就是無法被線性正確分類因此Logistic Regression的 accuracy 比較差。